Universidad del Rosario | Escuela de Ciencias e Ingeniería







Sesión
Diplomado Ciencia de Datos

Módulo
Machine Learning
Aprendizaje Supervisado

Fabián Sánchez Salazar

Noviembre de 2026

Sobre mi ☺

- Matemático, Magister y Doctor en Matemáticas de la Universidad Nacional.
- Más de 20 años de experiencia docente en diferentes universidades de Bogotá
- Líneas de investigación:
  - Modelamiento Matemático
  - Inteligencia Artificial-Machine Learning
  - Procesamiento de Lenguaje Natural
  - IA generativa
- Experiencia en cargos de dirección de programas.
- Actualmente me desempeño como profesor principal de carrera en la Escuela de Ciencias e Ingeniería de la Universidad del Rosario, donde también soy director de la Maestría en Matemáticas Aplicadas y Ciencias de la Computación.



FABIAN SANCHEZ SALAZAR
fabian.sanchez@urosario.edu.co

Contenidos del Módulo

- Conceptos fundamentales
- Problemas de Clasificación
  - Matriz de confusión
  - Escalamiento
  - Validación cruzada
  - Búsqueda en Grilla
- Modelos
- knn
- regresión logística
- árboles de decisión
- Problemas de Regresión
- Mse, mae, R^2
- Regresión lineal. Regressors
- Introducción a Redes Neuronales
- Clustering: kmeans, método del codo, inercia
- Reducción de dimensionalidad
- Análisis de Correspondencias.







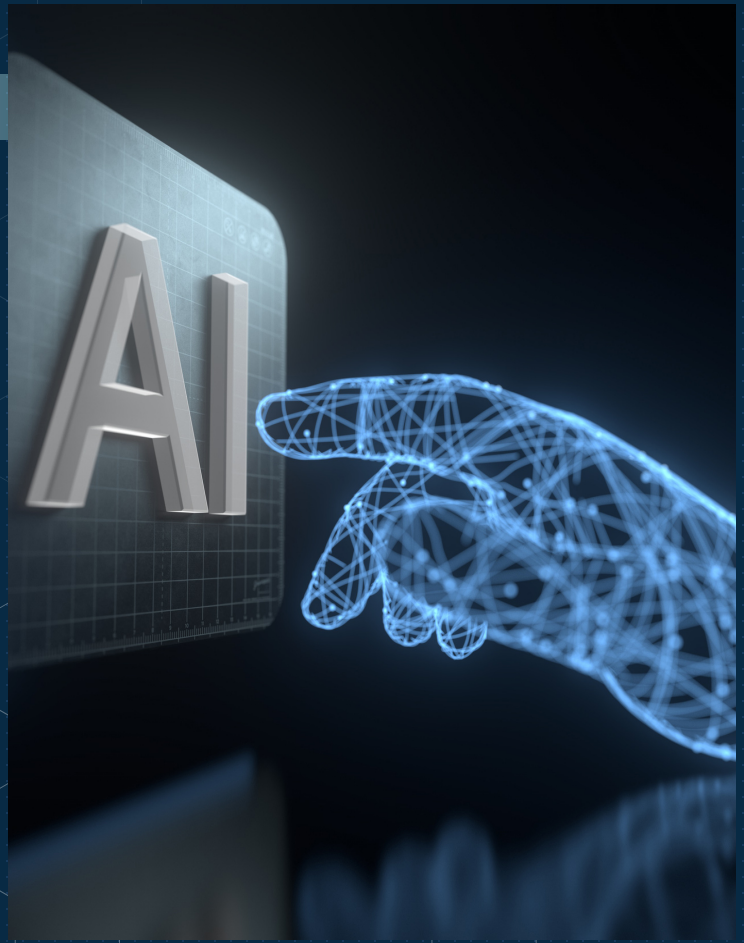
Google colab

1

INTRODUCCIÓN



Inteligencia Artificial



¿Qué es la Inteligencia Artificial?

La inteligencia artificial es una rama de la ciencia informática que tiene como objetivo diseñar tecnología que emule la inteligencia humana

¿Qué hacemos los humanos?

Resolver problemas

Tomar Decisiones

Crear Contenido



Comunicarse

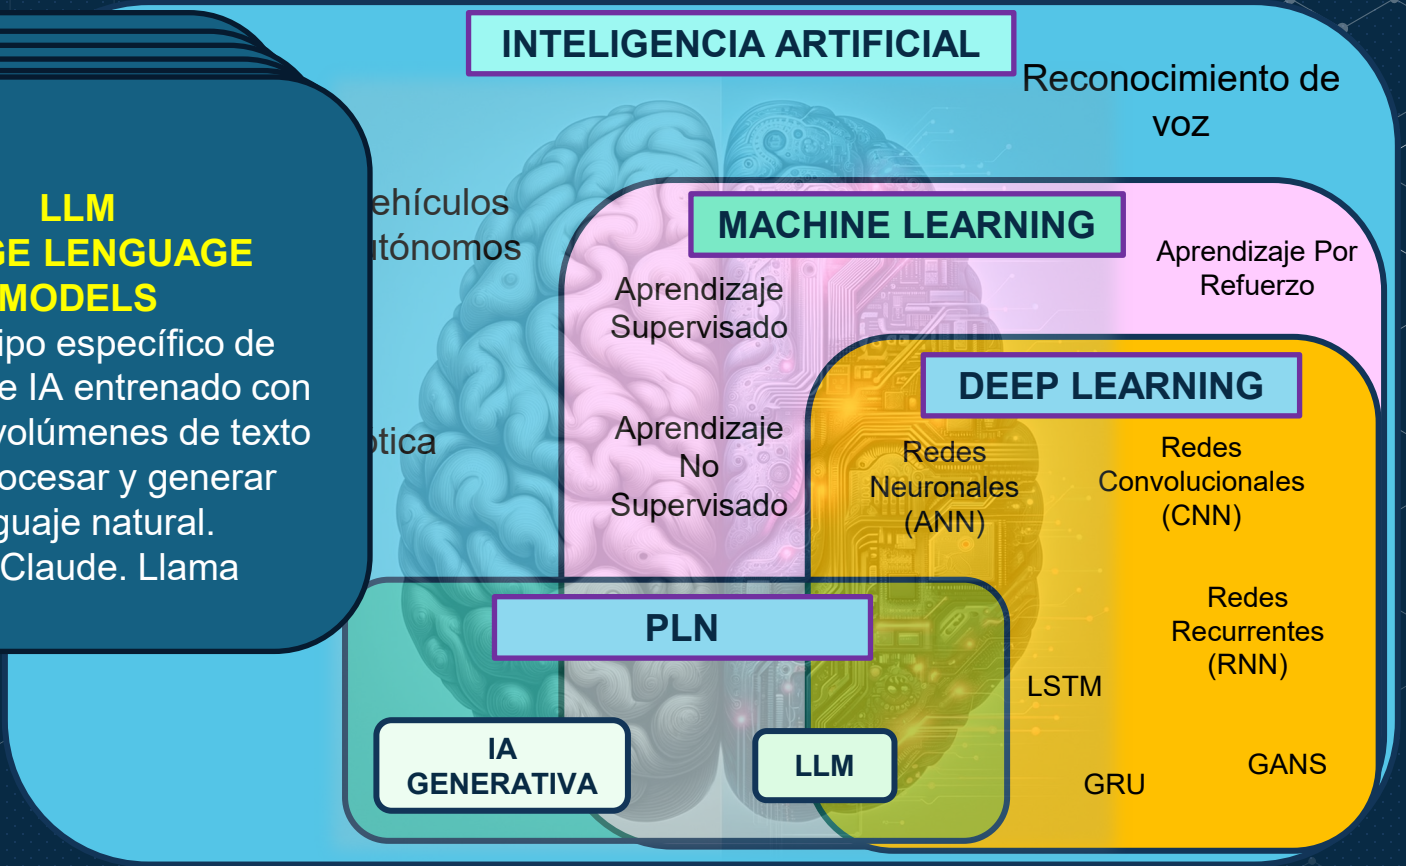
Realizar ciertas tareas

Aprender-Pensar

Subcampos de la IA

LLM
LARGE LENGUAGE MODELS

Es un tipo específico de modelo de IA entrenado con grandes volúmenes de texto para procesar y generar lenguaje natural.
Gp4-Claude. Llama



Tipos de Datos

DATOS ESTRUCTURADOS

Los datos estructurados son los que se pueden representar en una distribución fila-columna

DATAFRAME EN PYTHON

VARIABLES

COLUMNA C_j

PERSONA	EDAD	SEXO	ESTATURA	NIVEL ESCOLAR	MARCA DE AUTO	NÚMERO DE HIJOS	SALARIO
PERSONA 1	21	M	1,54	MAESTRÍA	AUDI	0	1200000
PERSONA 2	26	F	1,55	PROFESIONAL	RENAULT	5	1250000
PERSONA 3	30	F	1,6	DOCTORADO	BMW	2	900000
PERSONA 4	31	F	1,7	PROFESIONAL	RENAULT	2	800000
PERSONA 5	35	M	1,71	MAESTRÍA	AUDI	1	950000
PERSONA 6	65	M	1,8	MAESTRÍA	AUDI	1	2000000
PERSONA 7	45	M	1,54	MAESTRÍA	BMW	1	2500000

FILA F_i

DATOS NO ESTRUCTURADOS

Es cualquier forma de dato que no encaja en el modelo relacional o conjunto de tablas de bases de datos estructurados.









Google Photos

Universidad del Rosario

2

Machine Learning





¿Qué es el Machine Learning?

Machine Learning (Aprendizaje Automático) es una rama de la inteligencia artificial que desarrolla algoritmos capaces de aprender patrones a partir de datos, con el objetivo de realizar predicciones y clasificaciones para apoyar la toma de decisiones en un contexto particular

Machine Learning

¿Cuándo se debe usar algoritmos de Machine Learning?

Depende de lo que queremos resolver y lo que estamos buscando en los datos

- **Predicciones**
- **Agrupamiento**

TIPOS DE APRENDIZAJE

- **Aprendizaje Supervisado**
- **Aprendizaje NO Supervisado**
- **Aprendizaje por Refuerzo**

Universidad del Rosario

2.1

Aprendizaje Supervisado



Aprendizaje Supervisado

Es un tipo de Inteligencia Artificial / Machine Learning en el que: El modelo aprende a partir de ejemplos que ya tienen una respuesta (es decir, datos etiquetados). El sistema analiza esos ejemplos y aprende la relación entre entradas y salidas para luego predecir la respuesta de nuevos datos.

Ejemplo 1: Predicción de diabetes

Variables Predictoras

Variable Objetivo

	Pregnancies	Glucose	Blood Pressure	Skin Thickness	Insulin	BMI	Diabetes PedigreeFunction	Age	DIABETES
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1

Categórica Discreta

Algoritmos de Clasificación

¿Será posible predecir que una paciente tenga diabetes a partir de un conjunto de variables predictoras?

Universidad del Rosario | Escuela de Ciencias e Ingeniería

¿Qué es eso de la predicción?

Variables Predictoras

Variable Objetivo

	Pregnancies	Glucose	Blood Pressure	Skin Thickness	Insulin	BMI	Diabetes PedigreeFunction	Age	DIABETES
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1

El modelo aprende relaciones (patrones) de la datos.
Relaciones entre las variables predictoras y la variable objetivo
Para luego clasificar nuevos registros

Nuevos Registros

5	130	56	20	90	45.3	0.18	45
2	120	60	23	90	30.1	0.6	35

?

✓ Diabetes
✓ No diabetes

Aprendizaje Supervisado

Ejemplo 2: Asignación de tarjeta de crédito

Variable Objetivo → Variables Predictoras

card	reports	age	income	share	expenditure	owner	selfemp	dependents	months	majorcards	active
yes	0	37,67	4,52	0,03	124,98	yes	no	3	54	1	12
no	0	33,25	2,42	0,01	9,85	no	no	3	34	1	13
yes	0	33,67	4,50	0,00	15,00	yes	no	4	58	1	5
no	0	30,50	2,54	0,07	137,87	no	no	0	25	1	7
yes	0	32,17	9,79	0,07	546,50	yes	no	2	64	1	5

¿Será posible predecir la asignación de tarjeta de crédito (card) a partir de un conjunto de variables predictoras?

Aprendizaje Supervisado

Ejemplo 3: Riesgo de Cancelación

Variables Predictoras

Variable Objetivo

edad	ingreso mensual_usd	visitas web_semana	llamadas soporte_mes	antigüedad meses	usa app	riesgo cancelacion
22	650	5	0	3	1	Alto
35	1800	2	1	18	1	Bajo
29	1200	4	2	10	0	Medio
41	2400	1	0	30	1	Bajo
26	900	6	3	6	0	Alto
33	1500	3	1	14	1	Medio
48	3200	1	0	48	1	Bajo
31	1100	5	2	9	0	Medio

¿Será posible predecir el riesgo de cancelación de un cliente a partir de un conjunto de variables predictoras?

Aprendizaje Supervisado

Variables Predictoras

Variable Objetivo

index	TV	Radio	Newspaper	Web	Sales
0	230.1	37.8	69.2	306,634	22.1
1	44.5	39.3	45.1	302,653	10.4
2	17.2	45.9	69.3	49,490	9.3
3	151.5	41.3	58.5	257,816	18.5
4	180.8	10.8	58.4	195,660	12.9

Numérica continua

Algoritmos de Regresión

¿Será posible predecir las ventas a partir de la inversión destinada a diferentes medio de pauta publicitaria?

Ejemplo 2: Precio de Apartamento

Variables Predictoras → ← VARIABLE OBJETIVO

tamano m2	habitaciones	banos	edad edificio	distancia centro_km	tiene parqueadero	precio apartamento usd
45	1	1	20	8	0	95000
60	2	1	15	6	1	135000
80	3	2	10	5	1	185000
55	2	1	25	9	0	110000
120	3	2	5	4	1	260000
70	2	2	12	7	1	165000
40	1	1	30	10	0	80000
95	3	2	8	3	1	220000

¿Será posible predecir el precio de un apartamento a partir de algunas características de este?

Flujo general de ML en aprendizaje supervisado



Aplicaciones del Machine Learning: Supervisado



Predicción de enfermedades cardiovasculares

Los modelos se entrenan con datos históricos de pacientes, como edad, presión arterial, colesterol, frecuencia cardíaca y antecedentes médicos.
Algoritmos: Regresión logística, Random Forest, SVM, XGBoost.
Aplicación: Clasificar pacientes según su riesgo de desarrollar enfermedades cardiovasculares, facilitando la detección temprana y la prevención.
Tipo de problema: Clasificación.



Predicción del tiempo de hospitalización

Los hospitales utilizan registros históricos de diagnósticos, edad, enfermedades preexistentes, tratamientos y resultados de laboratorio.
Algoritmos: Regresión lineal, Random Forest Regressor, XGBoost, redes neuronales.
Aplicación: Predecir cuántos días permanecerá hospitalizado un paciente para mejorar la disponibilidad de camas y la planificación de recursos.
Tipo de problema: Regresión.

Universidad del Rosario

2.2

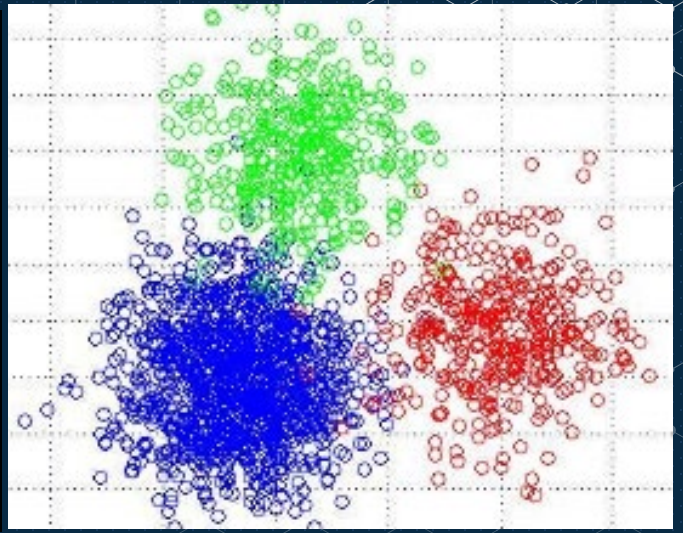
Aprendizaje No Supervisado



Aprendizaje NO Supervisado

Se buscan patrones o relaciones ocultas en el conjunto de datos. Pero en este caso no tenemos una variable objetivo definida (datos sin etiquetar)

edad	ingreso mensual usd	gasto mensual usd	visitas tienda mes	compras online mes	horas app semana	nivel educativo	uso_tarjeta credito mes	distancia tienda km
22	600	250	8	5	6	1	10	1,2
25	750	300	7	6	7	2	12	1,5
28	900	350	6	5	5	2	9	2
40	2000	600	3	2	2	3	6	4
45	2400	750	2	1	1	3	5	5,5
38	2100	680	3	2	2	3	7	4,5
31	1400	500	5	3	3	2	8	3
33	1500	520	4	3	3	2	9	3,2



¿Se pueden agrupar las personas de acuerdo con las características dadas?

Clustering

Aprendizaje NO Supervisado

Edad	IMC	Presión Sistólica	Colesterol LDL	Colesterol HDL	Glucosa en Ayunas	Frecuencia Cardíaca	Minutos de Ejercicio/Semana	Cigarrillos por Día	Riesgo Cardiovascular (Framingham)
68	31.5	158	182	38	156	88	20	15	28
55	28.2	142	160	42	132	82	60	5	18
46	25.1	126	135	55	104	72	180	0	8
37	23.4	118	110	62	91	68	250	0	3
74	33.8	166	190	35	168	94	10	20	34

¿Es posible identificar grupos de pacientes con perfiles de riesgo cardiovascular similares para diseñar programas de prevención y seguimiento diferenciados?

Clustering

Aprendizaje NO Supervisado

Nombre	Sexo	Estrato	Fuma	Glucose	Blood Pressure		Skin Thickness	Insulin	BMI	Diabetes PedigreeFunction	Age
Juan	M	3	1	148	72		35	0	33.6	0.627	50
Carlos	M	2	0	85	66	...	29	0	26.6	0.351	31
Ana	F	3	1	183	64		0	0	23.3	0.672	32
María	F	4	1	89	66		23	94	28.1	0.167	21
Hugo	M	3	0	137	40		35	168	43.1	2.288	33

n- variables

¿Se puede reducir el número de variables tratando de conservar la mayor cantidad de información posible?

Reducción de dimensionalidad

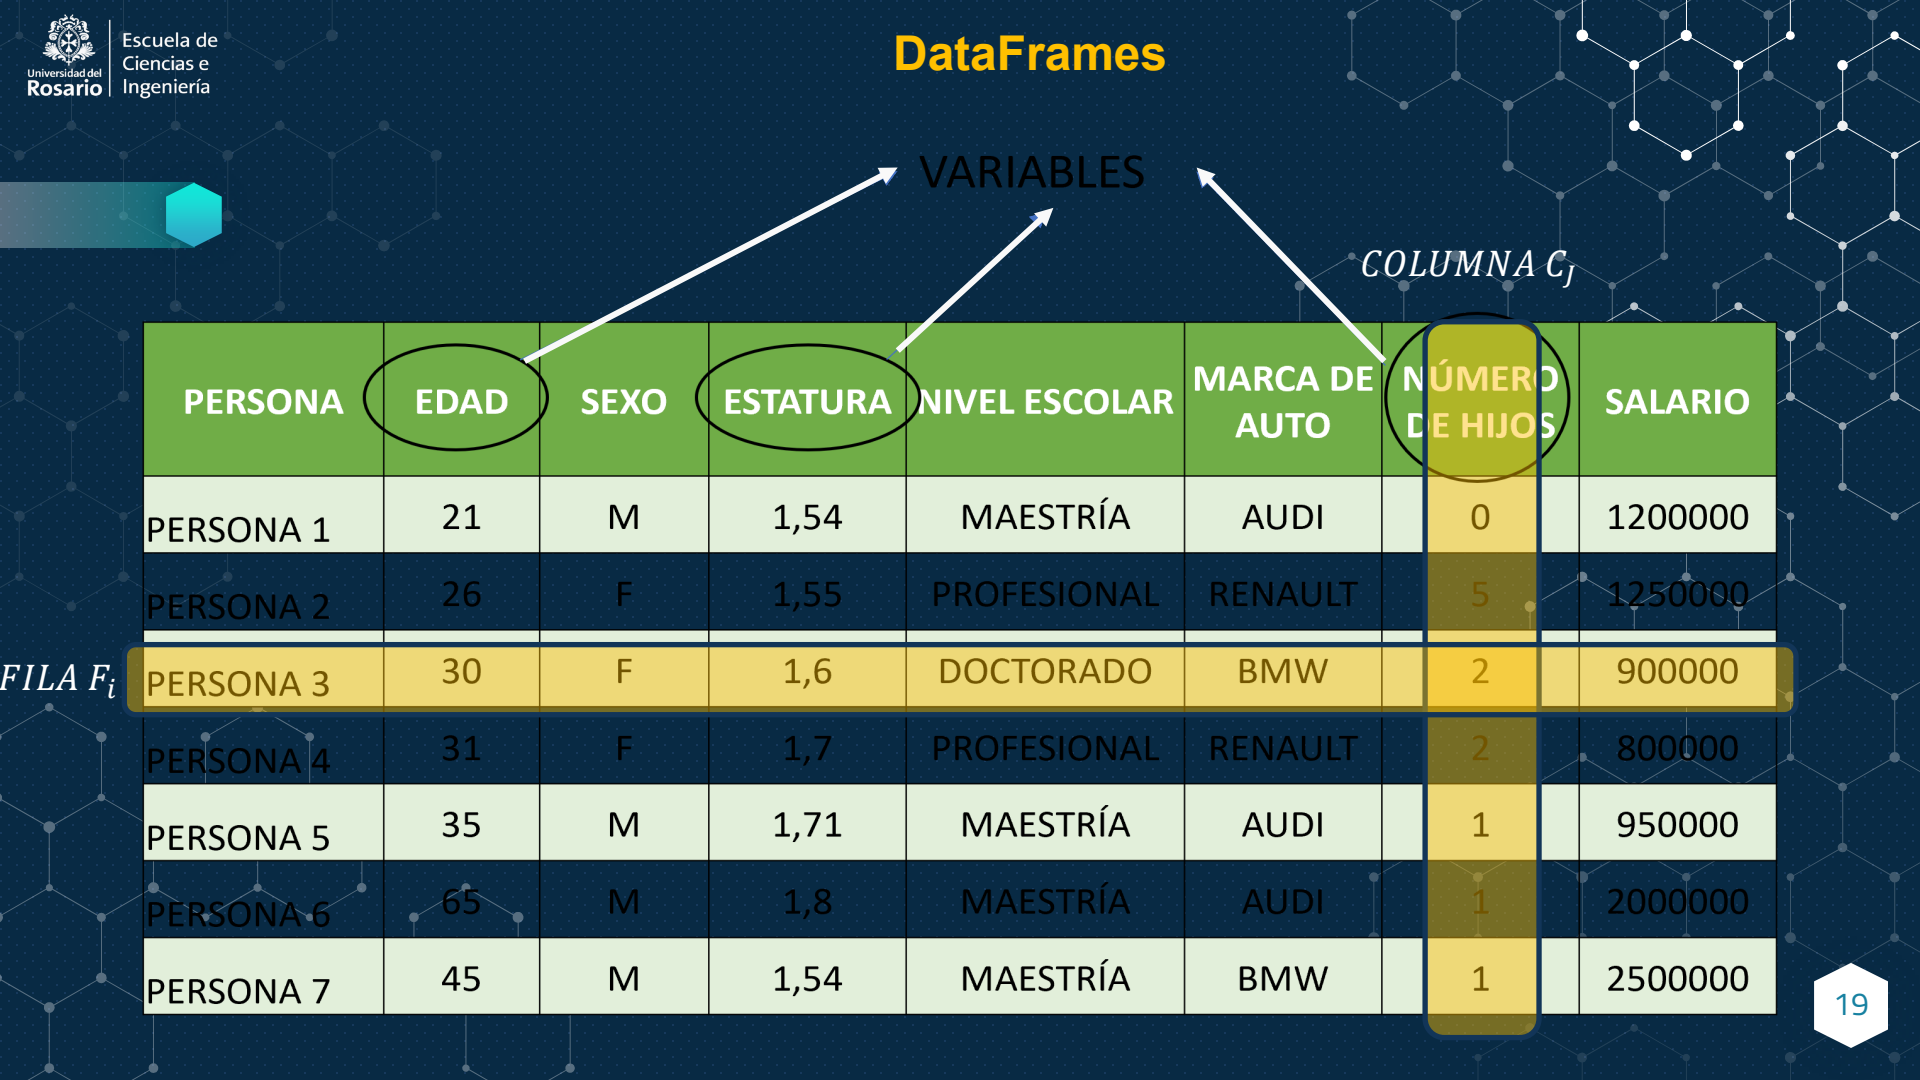
Universidad del Rosario | Escuela de Ciencias e Ingeniería

2

EDA (Exploratory Data Analysis)



DataFrames



PERSONA	EDAD	SEXO	ESTATURA	NIVEL ESCOLAR	MARCA DE AUTO	NÚMERO DE HIJOS	SALARIO
PERSONA 1	21	M	1,54	MAESTRÍA	AUDI	0	1200000
PERSONA 2	26	F	1,55	PROFESIONAL	RENAULT	5	1250000
PERSONA 3	30	F	1,6	DOCTORADO	BMW	2	900000
PERSONA 4	31	F	1,7	PROFESIONAL	RENAULT	2	800000
PERSONA 5	35	M	1,71	MAESTRÍA	AUDI	1	950000
PERSONA 6	65	M	1,8	MAESTRÍA	AUDI	1	2000000
PERSONA 7	45	M	1,54	MAESTRÍA	BMW	1	2500000

Universidad del Rosario | Escuela de Ciencias e Ingeniería

Análisis Exploratorio de Datos

Paso 1
Preguntas a responder

Paso 2
Generalidades del conjunto de datos

Paso 3
Tipos de variables

Paso 4
Estadística Descriptiva

Paso 5
Visualización-Gráficas

Paso 6
Relación entre variables

Paso 7
Reporte de conclusiones y resultados



ANÁLISIS

- Datos faltantes
- Datos Atípicos

Universidad del Rosario | Escuela de Ciencias e Ingeniería

EDA: Medidas Estadísticas

MEDIA

MEDIANA

MODA

VARIANZA

MÁXIMO

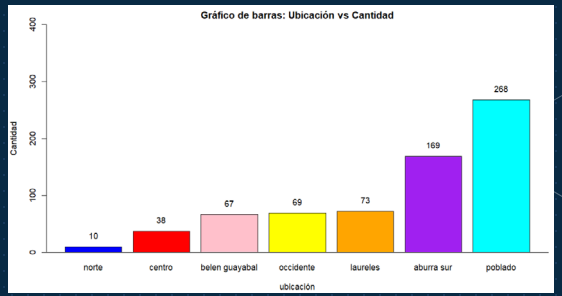
MÍNIMO

CUARTILES

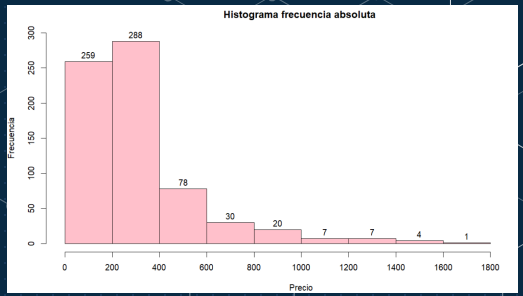
DESVIACIÓN ESTANDAR

CORRELACIÓN

GRÁFICO DE BARRAS



HISTOGRAMA



BOXPLOT

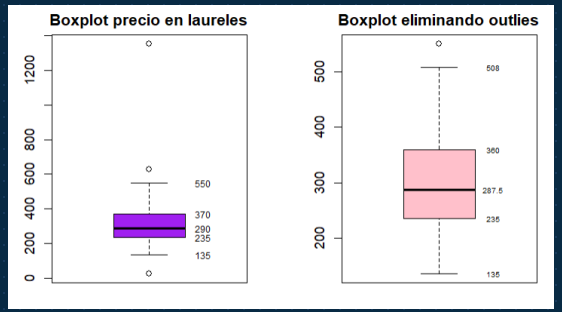
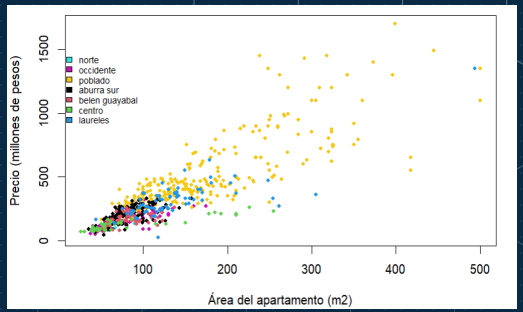


DIAGRAMA DE DISPERSIÓN



Universidad del Rosario | Escuela de Ciencias e Ingeniería

3

Proceso de Machine Learning Supervisado



Identificación de Variables

1

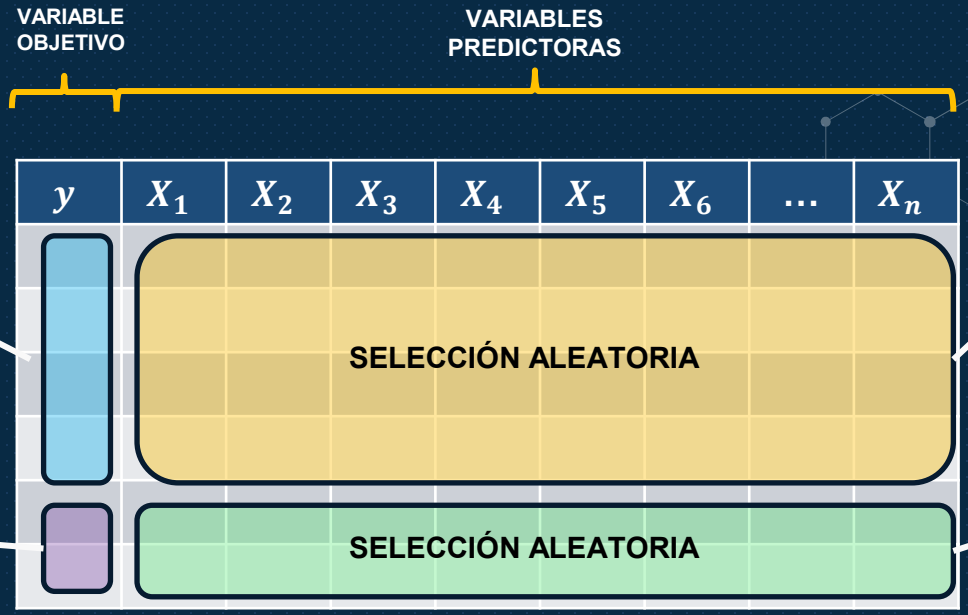
Variable Objetivo

Variables Predictoras

y	X_1	X_2	X_3	X_4	X_5	X_6	…	X_n

Conjunto de Entrenamiento y Prueba

2



Conjunto de entrenamiento en y

y_{train}

Conjunto de Prueba en y

y_{test}

Conjunto de entrenamiento en x

x_{train}

Conjunto de Prueba en x

x_{test}

La proporciones recomendadas para entreamiento y prueba

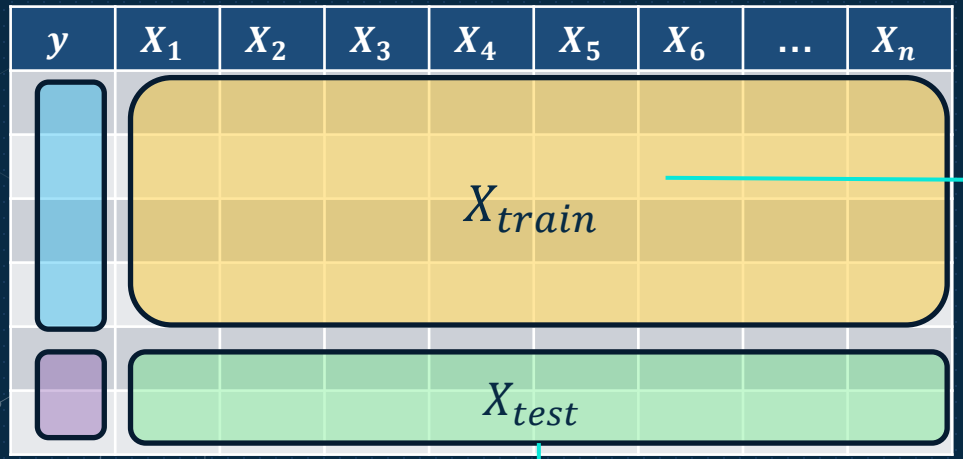
$70\% - 30\%$ $80\% - 20\%$ $75\% - 25\%$

Escalar las Variables

3

VARIABLE OBJETIVO

VARIABLES PREDICTORAS



fit.transform

μ_{train}

σ_{train}

$$\frac{X_{train} - \mu_{train}}{\sigma_{train}}$$

.transform

$$\frac{X_{test} - \mu_{train}}{\sigma_{train}}$$

Selección de Modelos

4

Clasificación

1. K-Vecinos más cercanos (kNN)
2. Regresión Logística
3. Árboles de Decisión (classifier)
4. Random Forest
5. Naive Bayes
6. Support vector machine (SVC)
7. Gradient Boosting
8. Multilayer Perceptron (MLP)
9. Redes Neuronales

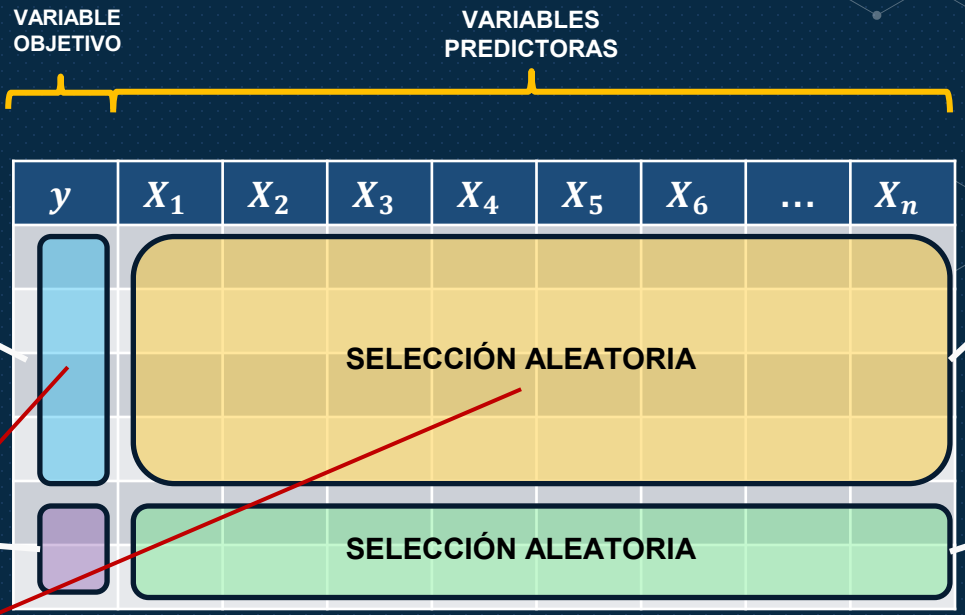
Regresión

1. k-Vecinos más cercanos (kNN)
2. Regresión Lineal (Simple-Múltiple)
3. Árboles de Decisión (regressor)
4. Random Forest
5. Support vector machine (SVR)
6. Gradient Boosting
7. Multilayer Perceptron (MLP)
8. Redes Neuronales

Universidad del Rosario | Escuela de Ciencias e Ingeniería

Entrenar el Modelo

5



Conjunto de **entrenamiento** en y

y_{train}

Conjunto de **Prueba** en y

y_{test}

Conjunto de **entrenamiento** en x

x_{train}

Conjunto de **Prueba** en x

x_{test}

Entrenamos el Modelo con estos conjuntos

$Modelo(X_{train}, y_{train})$

Tomamos el modelo entrenado y lo evaluamos en X_{test}

$y_{pred} = Modelo_entrenado(X_{test})$

Evaluación del Modelo

6

Tomamos el modelo y lo evaluamos en X_{test}

$$y_{pred} = Modelo_entrenado(X_{test})$$

Vamos a comparar los valores que nos da el modelo en X_{test} y los valores reales y_{test}

Clasificación

Matriz de Confusión + Métricas

- Accuracy
- Recall
- Specificy
- Precision
- F1-Score

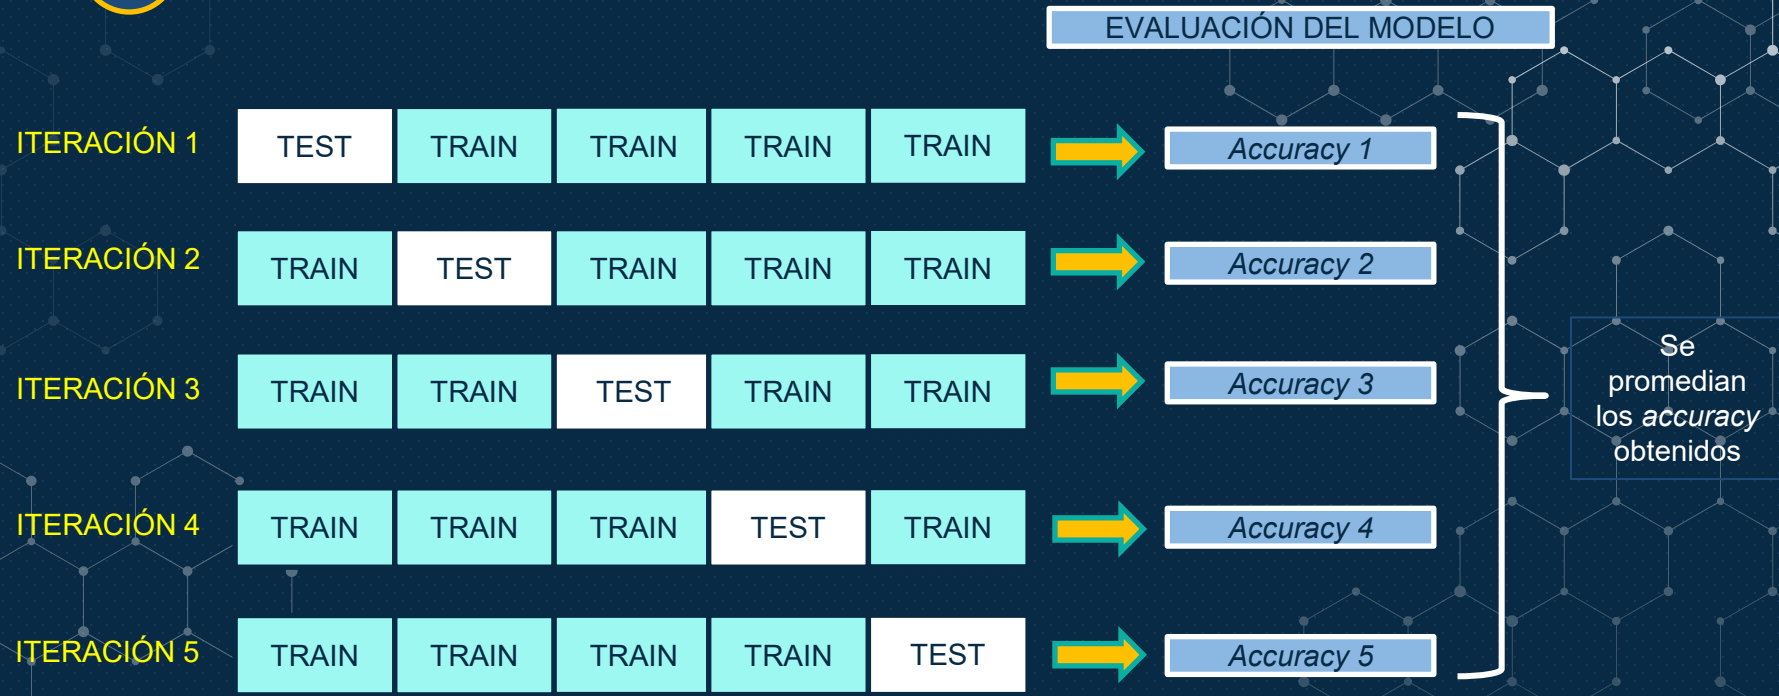
Regresión

Métricas

- Mse (error cuadrático medio)
- R^2 coeficiente de determinación
- RMSE

Validación Cruzada

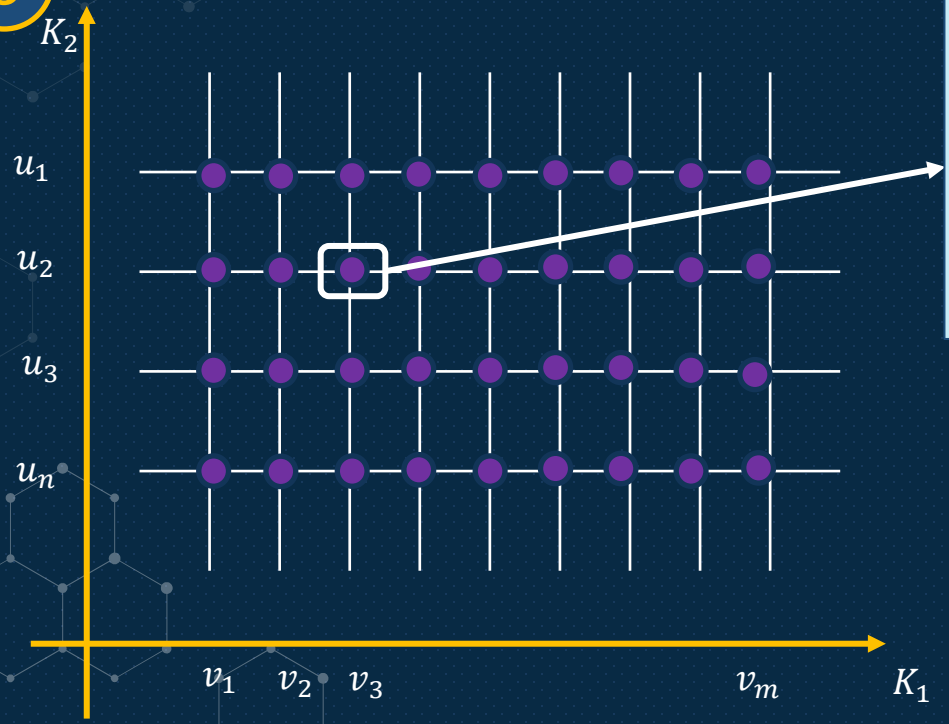
7

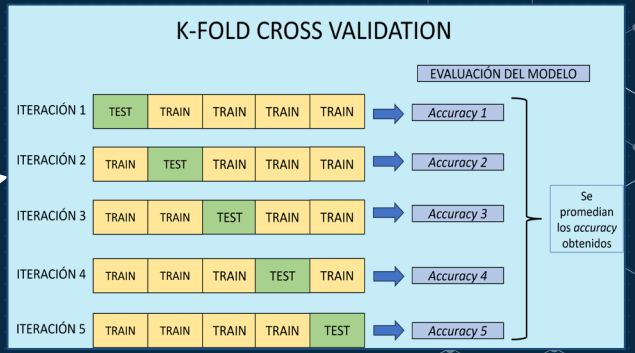


Optimización de Hiperparámetros

8

Grid Search





Se hace validación cruzada en cada combinación de parámetros

Se selecciona el mejor modelo

Universidad del Rosario | Escuela de Ciencias e Ingeniería

4

Ideas Intuitivas de Algunos Modelos de Clasificación

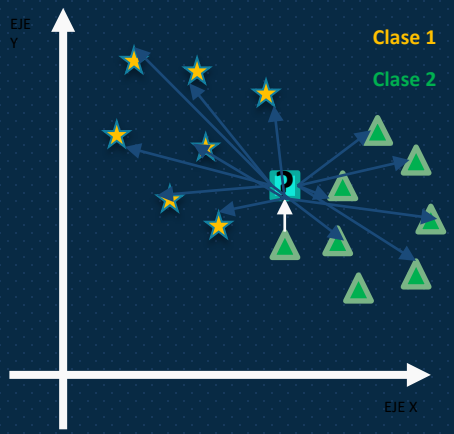


K-vecinos más cercanos

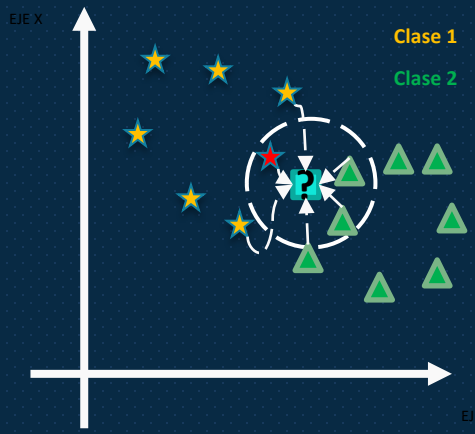
DATO INICIAL



CALCULAR LAS DISTANCIAS



ENCONTRANDO LOS VECINOS Y VOTANDO





Se calculan todas las distancias del cuadro a todos los otros puntos y se ordenan las distancias de menor a mayor

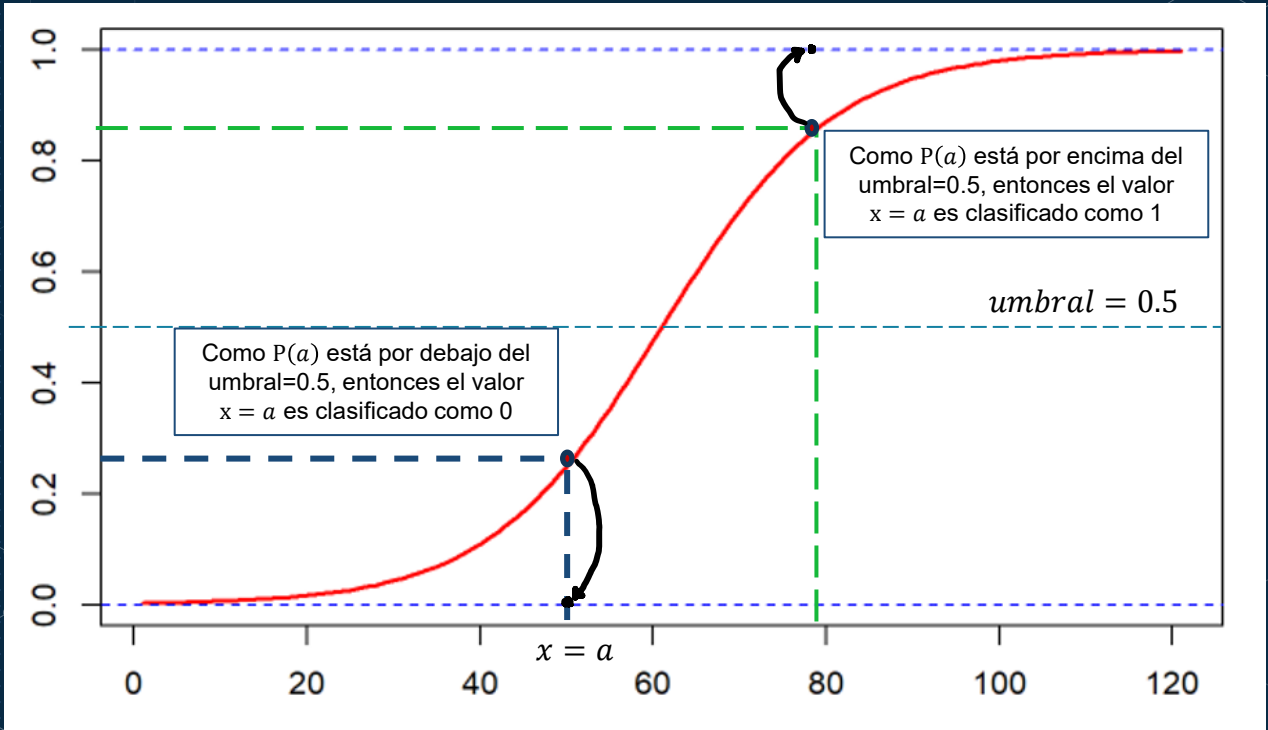
Los vecinos más cercanos serán aquellos que tengan distancias más pequeñas.

Se elije un número determinado de vecinos (k).

La clasificación se hace de acuerdo con la clase mayoritaria (mayor número de elementos)

Regresión Logística

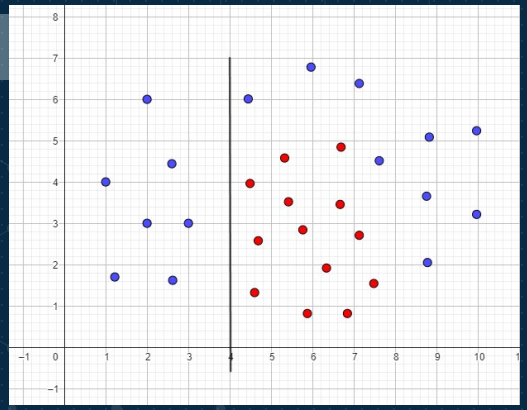
$$P(a) = P(\mathrm{y} = 1 | x = a) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 a)}}$$



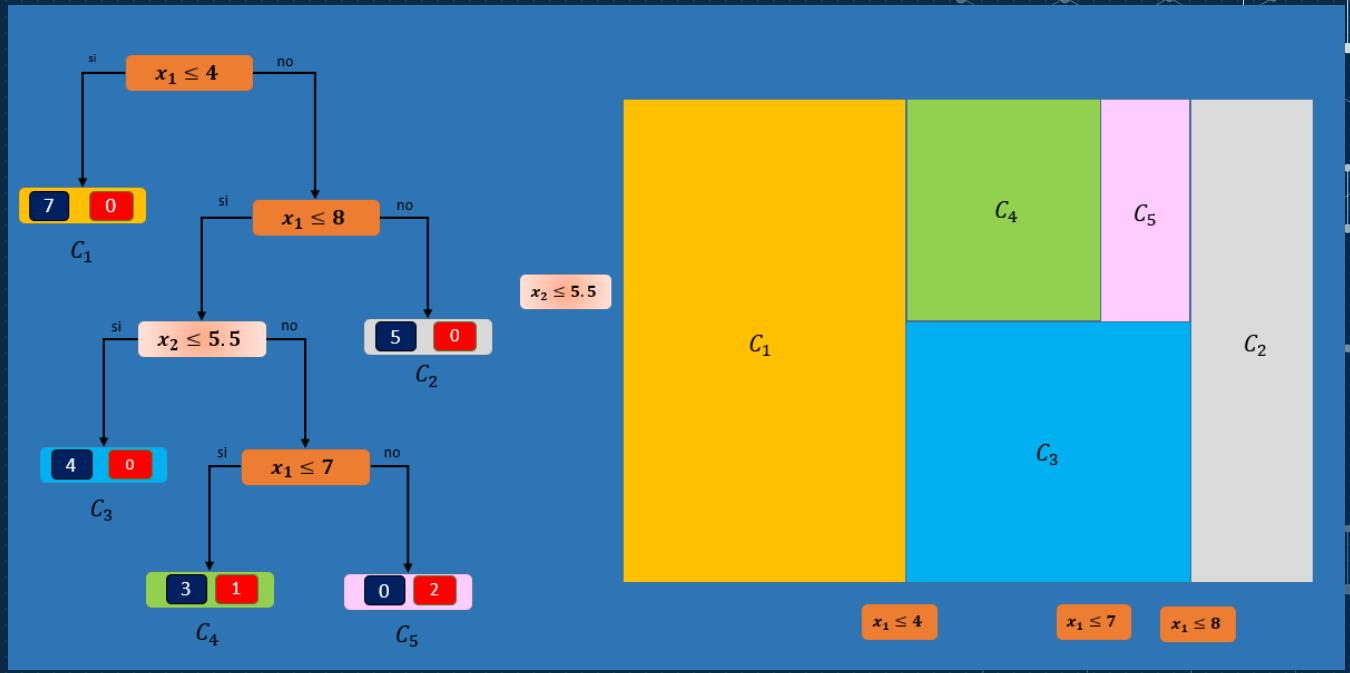
Función Sigmoide

$$f(x) = \frac{1}{1 + e^{-x}}$$

Árboles de Decisión



¿Cómo podemos separar estos puntos con líneas verticales u horizontales?



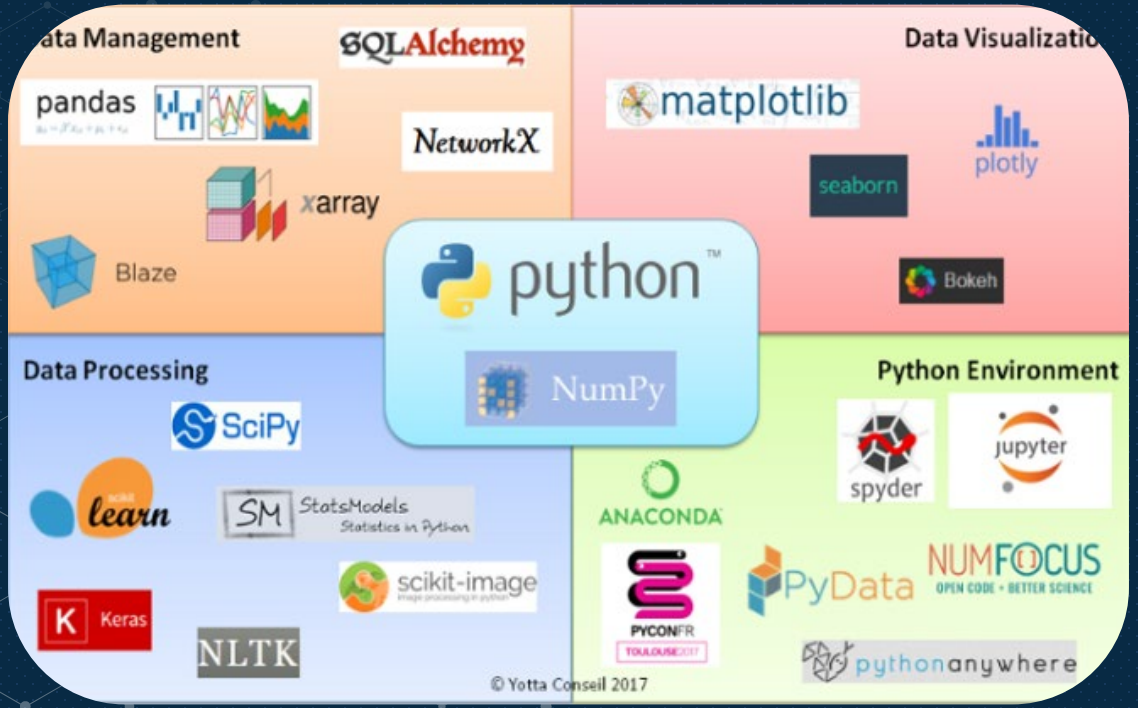
Universidad del Rosario | Escuela de Ciencias e Ingeniería

5

SOFTWARE



PYTHON



Google colab

jupyter

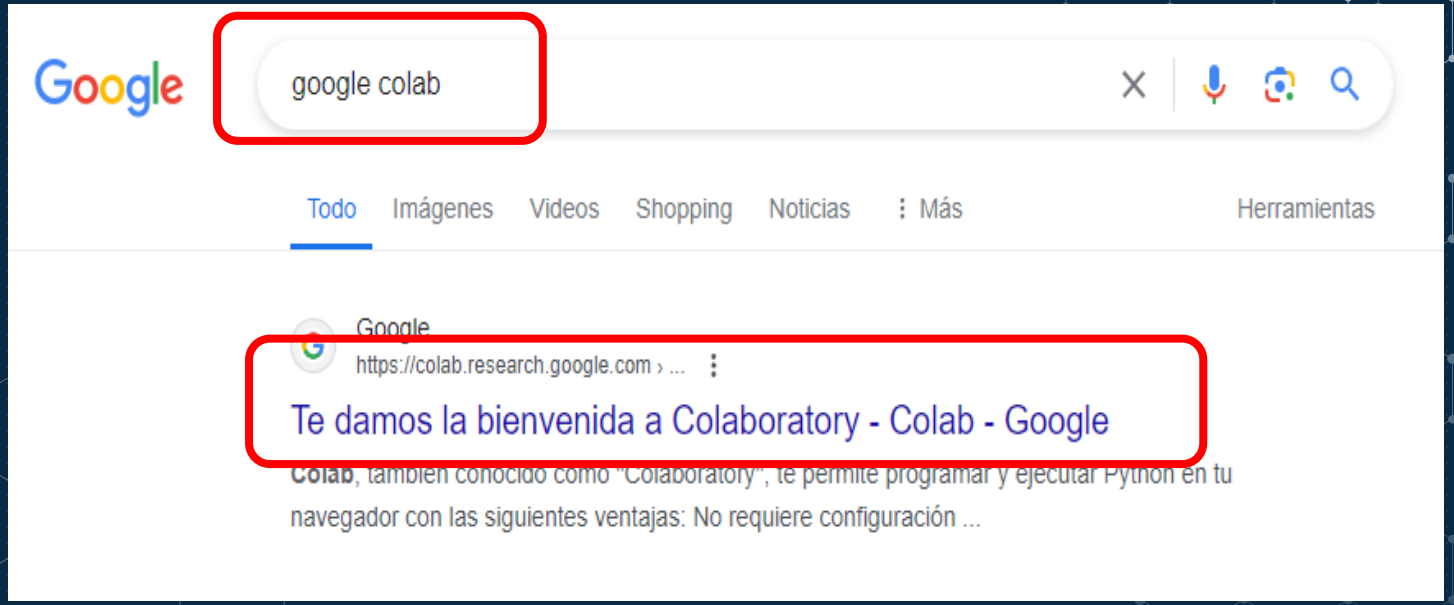
Visual Studio Code

PyCharm

ANACONDA

PYTHON+COLAB





PYTHON+COLAB

Te damos la bienvenida a Colaboratory

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Compartir | Iniciar sesión

Índice

+ Código + Texto Copiar en Drive

Conectar

Primeros pasos

Ciencia de datos

Aprendizaje automático

Más recursos

Ejemplos destacados

+ Sección

Te damos la bienvenida a Colab

(Novedad) Prueba la API de Gemini

- Generate a Gemini API key
- Talk to Gemini with the Speech-to-Text API
- Gemini API: Quickstart with Python
- Gemini API code sample
- Compare Gemini with ChatGPT
- More notebooks

Si ya conoces Colab, echa un vistazo a este vídeo para obtener información sobre las tablas interactivas, la vista del historial de código ejecutado y la paleta de comandos.



PYTHON+COLAB

Te damos la bienvenida a Colaboratory

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Nuevo cuaderno 1

Abrir cuaderno Ctrl+O

Subir cuaderno

Cambiar nombre

Guardar una copia en Drive

Guardar una copia como Gist de GitHub

Guardar una copia en GitHu

Guardar

Historial de revisiones

Descargar

Imprimir

+ Texto | Copiar en Drive

mos la bienvenida a

dad) Prueba la API de G

erate a Gemini API key

3

CREAR UNA CUENTA DE GOOGLE GMAIL

Gmail

2

Es necesario iniciar sesión en Google

Debes iniciar sesión con una cuenta de Google para continuar.

Iniciar sesión

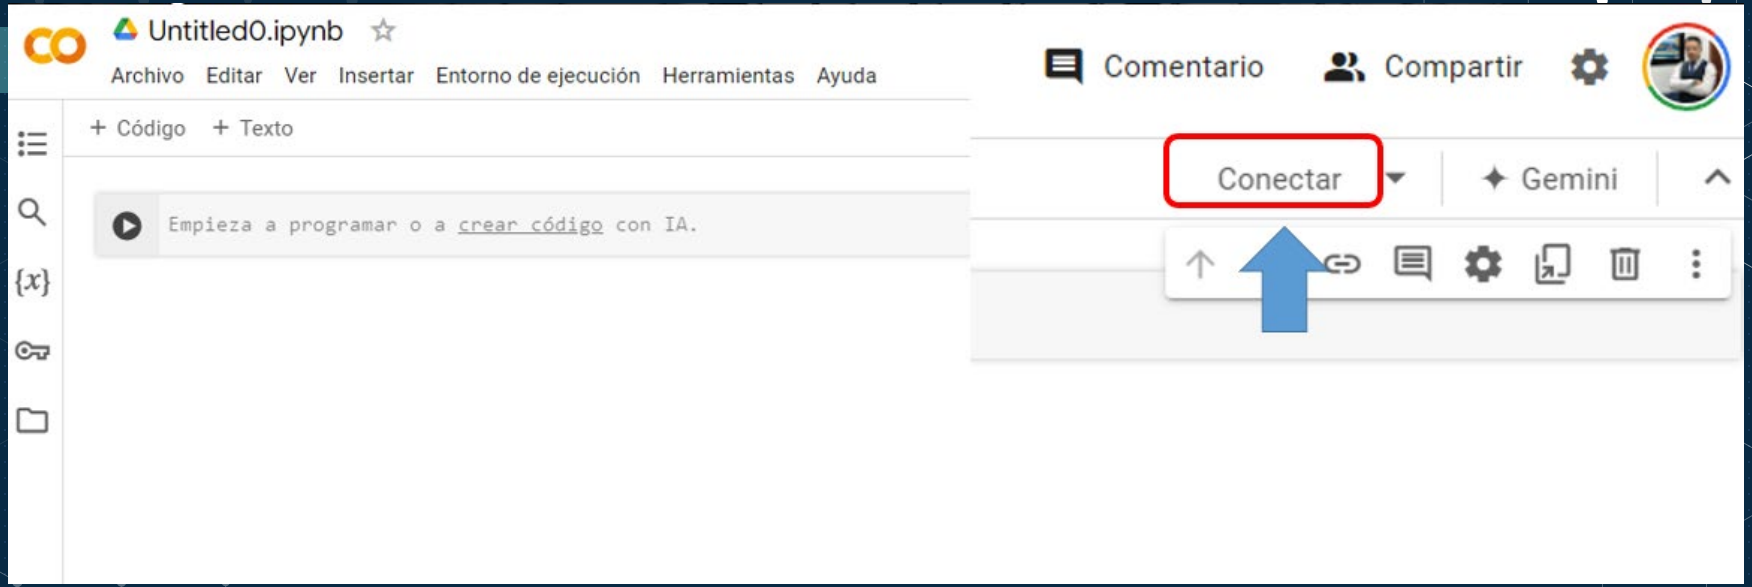
mación sobre las tablas interactiv



PYTHON+COLAB



PYTHON+COLAB



PYTHON+COLAB

¡Ahora, a trabajar en Colab!



Gracias!



fabian.sanchez@urosario.edu.co