



Sesión Diplomado Ciencia de Datos

Módulo Machine Learning Aprendizaje Supervisado

Fabián Sánchez Salazar

Contenidos del Módulo

- Conceptos fundamentales
- Problemas de Clasificación
 - Matriz de confusión
 - Escalamiento
 - Validación cruzada
 - Búsqueda en Grilla
- Modelos
 - knn
 - regresión logística
 - árboles de decisión
- Problemas de Regresión
 - Mse, mae, R^2
 - Regresión lineal. Regressors
- Introducción a Redes Neuronales
- Clustering: kmeans, método del codo, inercia
- Reducción de dimensionalidad
- Análisis de Correspondencias.




1

INTRODUCCIÓN



Conceptos IA



Conceptos IA

INTELIGENCIA ARTIFICIAL

Campo de las ciencias de la computación que se enfoca en crear y entrenar máquinas para realizar tareas inteligentes. Imitar lo que hace el humano

MACHINE LEARNING

Se basa en la creación de algoritmos por medio de los cuales se busca hacer predicciones o reconocer patrones en un conjunto de datos

DEEP LEARNING

Es un subcampo del machine learning en los cuales los algoritmos están inspirados en el funcionamiento de la neurona humana (redes neuronales)

PROCESAMIENTO DE LENGUAJE NATURAL

Subcampo de la IA que permite la comunicación entre el humano y la máquina por medio de lenguaje natural





DATOS

Conceptos IA

INTELIGENCIA ARTIFICIAL GENERATIVA

Es una rama de la inteligencia artificial que puede crear contenido como texto, audio, vídeo, imágenes, etc.



LLM LARGE LANGUAGE MODEL

Es un tipo específico de modelo de IA entrenado con grandes volúmenes de texto para procesar y generar lenguaje natural.
Gp4-Claude. Llama

Tipos de Datos

DATOS ESTRUCTURADOS

Los datos estructurados son los que se pueden representar en una distribución fila-columna

DATAFRAME EN PYTHON

VARIABLES

COLUMNA C_j

PERSONA	EDAD	SEXO	ESTATURA	NIVEL ESCOLAR	MARCA DE AUTO	NÚMERO DE HIJOS	SALARIO
PERSONA 1	21	M	1,54	MAESTRÍA	AUDI	0	1200000
PERSONA 2	26	F	1,55	PROFESIONAL	RENAULT	5	1250000
PERSONA 3	30	F	1,6	DOCTORADO	BMW	2	900000
PERSONA 4	31	F	1,7	PROFESIONAL	RENAULT	2	800000
PERSONA 5	35	M	1,71	MAESTRÍA	AUDI	1	950000
PERSONA 6	65	M	1,8	MAESTRÍA	AUDI	1	2000000
PERSONA 7	45	M	1,54	MAESTRÍA	BMW	1	2500000

FILA F_i

DATOS NO ESTRUCTURADOS

Es cualquier forma de dato que no encaja en el modelo relacional o conjunto de tablas de bases de datos estructurados.



Google Photos

Machine Learning

¿Cuándo se debe usar
algoritmos de Machine
Learning?



Depende de lo que queremos
resolver y lo que estamos
buscando en los datos

TIPOS DE APRENDIZAJE

**Aprendizaje
Supervisado**

**Aprendizaje NO
Supervisado**

**Aprendizaje por
Refuerzo**

Aprendizaje Supervisado

Es un tipo de Inteligencia Artificial / Machine Learning en el que: El modelo aprende a partir de ejemplos que ya tienen una respuesta (es decir, datos etiquetados). El sistema analiza esos ejemplos y aprende la relación entre entradas y salidas para luego predecir la respuesta de nuevos datos.

→ VARIABLES PREDICTORAS ←

VARIABLE
OBJETIVO

	Pregnancies	Glucose	Blood Pressure	Skin Thickness	Insulin	BMI	Diabetes PedigreeFunction	Age	DIABETES
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1

CATEGÓRICA-
DISCRETA



ALGORITMOS
DE
CLASIFICACIÓN

¿Será posible predecir que una paciente tenga diabetes a partir de un conjunto de variables predictoras?

¿Qué es eso de la predicción?

VARIABLES PREDICTORAS

VARIABLE
OBJETIVO

	Pregnancies	Glucose	Blood Pressure	Skin Thickness	Insulin	BMI	Diabetes PedigreeFunction	Age	DIABETES
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1

El modelo aprende relaciones (patrones) de la datos.
Relaciones entre las variables predictoras y la variable objetivo
Para luego clasificar nuevos registros



Nuevos
Registros

5	130	56	20	90	45.3	0.18	45
2	120	60	23	90	30.1	0.6	35



Diabetes
No diabetes

Aprendizaje Supervisado

Ejemplo 2: Asignación de Tarjeta de Crédito

VARIABLE
OBJETIVO

VARIABLES PREDICTORAS

card	reports	age	income	share	expenditure	owner	selfemp	dependents	months	majorcards	active
yes	0	37,67	4,52	0,03	124,98	yes	no	3	54	1	12
no	0	33,25	2,42	0,01	9,85	no	no	3	34	1	13
yes	0	33,67	4,50	0,00	15,00	yes	no	4	58	1	5
no	0	30,50	2,54	0,07	137,87	no	no	0	25	1	7
yes	0	32,17	9,79	0,07	546,50	yes	no	2	64	1	5

¿Será posible predecir la asignación de tarjeta de crédito (card) a partir de un conjunto de variables predictoras?

Ejemplo 3: Riesgo de Cancelación

→ VARIABLES PREDICTORAS ←

VARIABLE
OBJETIVO

edad	ingreso mensual_usd	visitas web_semana	llamadas soporte_mes	antigüedad meses	usa app	riesgo cancelacion
22	650	5	0	3	1	Alto
35	1800	2	1	18	1	Bajo
29	1200	4	2	10	0	Medio
41	2400	1	0	30	1	Bajo
26	900	6	3	6	0	Alto
33	1500	3	1	14	1	Medio
48	3200	1	0	48	1	Bajo
31	1100	5	2	9	0	Medio

¿Será posible predecir el riesgo de cancelación de un cliente a partir de un conjunto de variables predictoras?

Aprendizaje Supervisado

→ VARIABLES PREDICTORAS ← VARIABLE OBJETIVO

index	TV	Radio	Newspaper	Web	Sales
0	230.1	37.8	69.2	306,634	22.1
1	44.5	39.3	45.1	302,653	10.4
2	17.2	45.9	69.3	49,490	9.3
3	151.5	41.3	58.5	257,816	18.5
4	180.8	10.8	58.4	195,660	12.9

NUMÉRICA
CONTINUA



ALGORITMOS
DE REGRESIÓN

¿Será posible predecir las ventas a partir de la inversión destinada a diferentes medio de pauta publicitaria?

Ejemplo 2: Precio de Apartamento

VARIABLES PREDICTORAS

VARIABLE
OBJETIVO

tamano m2	habitaciones	banos	edad edificio	distancia centro_km	tiene parqueadero	precio apartamento usd
45	1	1	20	8	0	95000
60	2	1	15	6	1	135000
80	3	2	10	5	1	185000
55	2	1	25	9	0	110000
120	3	2	5	4	1	260000
70	2	2	12	7	1	165000
40	1	1	30	10	0	80000
95	3	2	8	3	1	220000

¿Será posible predecir el precio de un apartamento a partir de algunas características de este?


Flujo general de ML en aprendizaje supervisado



Aprendizaje NO Supervisado

Se buscan patrones o relaciones ocultas en el conjunto de datos. Pero en este caso no tenemos una variable objetivo definida (datos sin etiquetar)

edad	ingreso mensual usd	gasto mensual usd	visitas tienda mes	compras online mes	horas app semana	nivel educativo	uso_tarjeta credito mes	distancia tienda km
22	600	250	8	5	6	1	10	1,2
25	750	300	7	6	7	2	12	1,5
28	900	350	6	5	5	2	9	2
40	2000	600	3	2	2	3	6	4
45	2400	750	2	1	1	3	5	5,5
38	2100	680	3	2	2	3	7	4,5
31	1400	500	5	3	3	2	8	3
33	1500	520	4	3	3	2	9	3,2



¿Se pueden agrupar las personas de acuerdo con las características dadas?



CLUSTERING

Aprendizaje NO Supervisado

Nombre	Sexo	Estrato	Fuma	Glucose	Blood Pressure	...	Skin Thickness	Insulin	BMI	Diabetes Pedigree Function	Age
Juan	M	3	1	148	72		35	0	33.6	0.627	50
Carlos	M	2	0	85	66		29	0	26.6	0.351	31
Ana	F	3	1	183	64		0	0	23.3	0.672	32
María	F	4	1	89	66		23	94	28.1	0.167	21
Hugo	M	3	0	137	40		35	168	43.1	2.288	33

N- VARIABLES



¿Se puede reducir el número de variables tratando de conservar la mayor cantidad de información posible?



**REDUCCIÓN DE
DIMENSIONALIDAD**

2

EDA (Exploratory Data Analysis)



DataFrames

VARIABLES

COLUMNA C_j

PERSONA	EDAD	SEXO	ESTATURA	NIVEL ESCOLAR	MARCA DE AUTO	NÚMERO DE HIJOS	SALARIO
PERSONA 1	21	M	1,54	MAESTRÍA	AUDI	0	1200000
PERSONA 2	26	F	1,55	PROFESIONAL	RENAULT	5	1250000
PERSONA 3	30	F	1,6	DOCTORADO	BMW	2	900000
PERSONA 4	31	F	1,7	PROFESIONAL	RENAULT	2	800000
PERSONA 5	35	M	1,71	MAESTRÍA	AUDI	1	950000
PERSONA 6	65	M	1,8	MAESTRÍA	AUDI	1	2000000
PERSONA 7	45	M	1,54	MAESTRÍA	BMW	1	2500000

FILA F_i

Análisis Exploratorio de Datos



EDA: Medidas Estadísticas

MEDIA

MEDIANA

MODA

VARIANZA

MÁXIMO


MÍNIMO

CUARTILES


**DESVIACIÓN
ESTANDAR**

CORRELACIÓN

GRÁFICO DE BARRAS



HISTOGRAMA



BOXPLOT





DIAGRAMA DE DISPERSIÓN



3

Proceso de Machine Learning Supervisado



Identificación de Variables

1

VARIABLE
OBJETIVO

VARIABLES
PREDICTORAS

y	X_1	X_2	X_3	X_4	X_5	X_6	...	X_n

Conjunto de Entrenamiento y Prueba

2

VARIABLE
OBJETIVO

VARIABLES
PREDICTORAS

Conjunto de
entrenamiento en y
 y_{train}

Conjunto de Prueba
en y
 y_{test}



Conjunto de
entrenamiento en x
 x_{train}

Conjunto de
Prueba en x
 x_{test}

La proporciones recomendadas para entrenamiento y prueba

70% – 30%

80% – 20%

75% – 25%

Escalar las Variables

3

VARIABLE
OBJETIVO

VARIABLES
PREDICTORAS

y	X ₁	X ₂	X ₃	X ₄	X ₅	X ₆	...	X _n
	X _{train}							
	X _{test}							

fit.transform

μ_{train}

$$X_{train} - \mu_{train}$$

σ_{train}

σ_{train}

.transform

$$\frac{X_{test} - \mu_{train}}{\sigma_{train}}$$

Selección de Modelos

4

Clasificación

1. K-Vecinos más cercanos (kNN)
2. Regresión Logística
3. Árboles de Decisión (**classifier**)
4. Random Forest
5. Naive Bayes
6. Support vector machine (SVC)
7. Gradient Boosting
8. Multilayer Perceptron (MLP)
9. Redes Neuronales

Regresión

1. k-Vecinos más cercanos (kNN)
2. Regresión Lineal (Simple-Múltiple)
3. Árboles de Decisión (**regressor**)
4. Random Forest
5. Support vector machine (SVR)
6. Gradient Boosting
7. Multilayer Perceptron (MLP)
8. Redes Neuronales

Entrenar el Modelo

5

VARIABLE
OBJETIVO


VARIABLES
PREDICTORAS

Conjunto de
entrenamiento en y
 y_{train}

Conjunto de
entrenamiento en x
 x_{train}

Conjunto de Prueba
en y
 y_{test}

Conjunto de
Prueba en x
 x_{test}



Entrenamos el Modelo
con estos conjuntos

$Modelo(X_{train}, y_{train})$

Tomamos el modelo
entrenado y lo
evaluamos en x_{test}

$y_{pred} = Modelo_entrenado(x_{test})$

Evaluación del Modelo

6

Tomamos el modelo y lo evaluamos en X_{test}

$$y_{pred} = \text{Modelo_entrenado}(X_{test})$$



Vamos a comparar los valores que nos da el modelo en X_{test} y los valores reales y_{test}

Clasificación

Matriz de Confusión
+
Métricas

- Accuracy
- Recall
- Specificity
- Precision
- F1-Score

Regresión


Métricas

- Mse (error cuadrático medio)
- R^2 coeficiente de determinación
- RMSE

Validación Cruzada


7

ITERACIÓN 1



Accuracy 1

ITERACIÓN 2




Accuracy 2

ITERACIÓN 3




Accuracy 3

ITERACIÓN 4



Accuracy 4

ITERACIÓN 5



Accuracy 5



EVALUACIÓN DEL MODELO

Se
promedian
los *accuracy*
obtenidos

Optimización de Hiperparámetros

8

Grid Search



Se hace validación cruzada en cada combinación de parámetros

Se selecciona el mejor modelo

4

Ideas Intuitivas de Algunos Modelos de Clasificación




K-vecinos más cercanos


DATO INICIAL



CALCULAR LAS DISTANCIAS



ENCONTRANDO LOS VECINOS Y VOTANDO



Se calculan todas las distancias del cuadro a todos los otros puntos y se ordenan las distancias de menor a mayor


Los vecinos más cercanos serán aquellos que tengan distancias más pequeñas.

Se elije un número determinado de vecinos (k).

La clasificación se hace de acuerdo con la clase mayoritaria (mayor número de elementos)

Regresión Logística


$$P(a) = P(y = 1|x = a) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 a)}}$$




Función Sigmoide

$$f(x) = \frac{1}{1 + e^{-x}}$$

Árboles de Decisión



*¿Cómo podemos
separar estos puntos
con líneas verticales
u horizontales?*




5

SOFTWARE





PYTHON



Google
colab







Te damos la bienvenida a Colaboratory

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Compartir Iniciar sesión

Índice

Primeros pasos

Ciencia de datos

Aprendizaje automático

Más recursos

Ejemplos destacados

+ Sección


Te damos la bienvenida a Colab

(Novedad) Prueba la API de Gemini

- [Generate a Gemini API key](#)
- [Talk to Gemini with the Speech-to-Text API](#)
- [Gemini API: Quickstart with Python](#)
- [Gemini API code sample](#)
- [Compare Gemini with ChatGPT](#)
- [More notebooks](#)

Si ya conoces Colab, echa un vistazo a este vídeo para obtener información sobre las tablas interactivas, la vista del historial de código ejecutado y la paleta de comandos.

3 Cool Google Colab Features



Te damos la bienvenida a Colaboratory

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Nuevo cuaderno

Abrir cuaderno

Subir cuaderno

Cambiar nombre

Guardar una copia en Drive

Guardar una copia como Gist de GitHub

Guardar una copia en GitHub

Guardar

Historial de revisiones

Descargar

Imprimir

3

CREAR UNA CUENTA DE GOOGLE GMAIL




2

Es necesario iniciar sesión en Google

Debes iniciar sesión con una cuenta de Google para continuar.

[Iniciar sesión](#)



Te damos la bienvenida a Colaboratory

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Nuevo cuaderno

Abrir cuaderno Ctrl+O

Subir cuaderno

Cambiar nombre

Guardar una copia en Drive

Guardar una copia como Gist de GitHub

Guardar una copia en GitHub

Guardar Ctrl+S

Historial de revisiones

Descargar

Imprimir Ctrl+P

Textos Copiar en Drive

Te damos la bienvenida a Colab

Prueba la API de Gemini

[Generate a Gemini API key](#)

[Interact with Gemini with the Speech-to-Text API](#)

[Gemini API: Quickstart with Python](#)


[Gemini API code sample](#)

[Compare Gemini with ChatGPT](#)

[More notebooks](#)

Si ya conoces Colab, echa un vistazo a este vídeo para obtener información sobre las tablas interactivas ejecutadas y la paleta de comandos.

PYTHON+COLAB



The screenshot displays the Google Colab web interface. At the top, the title bar shows 'Untitled0.ipynb' with a star icon. Below the title bar is a menu bar with options: Archivo, Editar, Ver, Insertar, Entorno de ejecución, Herramientas, and Ayuda. On the left side, there is a sidebar with icons for file management and a search bar. The main workspace area contains a prompt: 'Empieza a programar o a [crear código](#) con IA.' On the right side, there is a toolbar with icons for commenting, sharing, settings, and a profile picture. The 'Conectar' button is highlighted with a red box, and a blue arrow points to it. The 'Compartir' button is also visible next to it.

¡Ahora, a trabajar en Colab!



Gracias!

